面向长程机器人任务的失败模式分析与过程级评测

实验报告（研究论文）V1.0

报告完成人： _____

完成日期：2026 年 9 月 28 日

目录

摘要 Abstract 2

1 引言 Introduction 2

1.1 研究背景 Background 2

1.2 现有方法的不足 Research Status 2

1.3 研究核心思路与贡献 Contributions 3

2 相关工作 Related Works 3

3 方法 Methods 3

3.1 任务定义与符号约定 Task Definition and Notations 3

3.2 评测总体框架 Framework 4

3.3 过程级指标 Key Components 4

4 实验 Experiments 4

4.1 数据集 Datasets 4

4.2 评估指标 Metrics 4

4.3 基线方法 Baselines 5

4.4 实现细节与实验设置 Implementation Details 5

4.5 实验主结果 Main Results 5

4.6 消融实验 Ablation Study 6

4.7 案例分析与错误分析 Case Study and Error Study 7

4.8 可视化分析 Visualizations 8

4.9 稳健性与泛化分析 Robustness and Generalization 8

5 讨论 Discussion 8

6 研究总结 Conclusions 9

6.1 主要工作总结 Conclusions 9

6.2 研究局限性 Limitations 9

6.3 未来改进方向 Future Works 9
7 参考文献 References 9
8 附录 Appendix 10

摘要 Abstract

长程机器人任务通常用整条序列成功率评价，但该指标只给出最终结果，不能说明失败发生在哪一步、动作为什么偏离，也不能判断失败后是否能够恢复。本研究以 CALVIN 仿真环境和官方 MCIL 预训练模型为对象，先用真实示范回放验证环境、绝对动作接口和成功判定，再开展单任务、100 条五步序列、动作分量替换、教师强制状态对照和固定重试实验。三类单任务共测试 27 次，其中打开 LED 成功 2/9，左移滑门和打开抽屉均为 0/9；LED 成功在相同条件下再次复现，均在第 94 个动作步达到成功条件。正式长程评测完成 100 条序列，完整成功 0 条。动作对照显示，三类任务只替换位置动作后均失败，只替换姿态仍能成功；自由滚动时位置动作与示范的平均距离扩大到 72.9—194.2 毫米。结果表明，当前模型不是完全没有任务能力，但闭环位置偏离、关键动作时机和初始状态差异会使长程成功率迅速归零。过程级记录能够在相同最终分数下给出更具体的失败证据。

关键词：长程机器人任务；CALVIN；MCIL；失败诊断；过程级评测

1 引言 Introduction

1.1 研究背景 Background

具身智能模型需要根据视觉观察和自然语言连续完成多个操作。长程任务与单步任务的区别不只是动作数量增加：前一步会改变物体位置、夹爪状态和后续任务的起点，任何偏差都可能进入下一步。CALVIN 通过连续五条语言指令评价这种技能组合能力[1]。

1.2 现有方法的不足 Research Status

CALVIN 的 SR@1 至 SR@5 和平均完成长度能反映性能随任务链变长而下降，但仍不能直接回答失败发生在哪里、哪类动作先偏离、一次重试是否有效。两条序列都得到 0 分时，一条可能接近完成，另一条可能从开始就没有找到目标；只看最终分数无法区分。

1.3 研究核心思路与贡献 Contributions

本研究不修改大型模型，也不追求新的排行榜成绩，而是在同一 MCIL 基线上补充可复查的过程证据。主要工作包括：验证仿真和动作管线；建立单任务、标准长程、动作拆分和重试诊断流程；用失败位置、任务类型、动作分量和恢复结果解释最终成功率遗漏的信息。

2 相关工作 Related Works

CALVIN 面向语言条件长程操作，包含 34 类操作技能和最多五步的连续任务链[1]。MCIL 使用多上下文模仿学习，根据图像或语言目标生成动作[3]。后续 HULC 工作进一步研究了离散潜在计划、视频与语言对齐等设计[2]。这些方法主要用序列完成率比较模型性能。

RT-2、OpenVLA 和 Octo 将大规模视觉语言或多机器人数据用于动作生成和跨任务泛化[4,5,9]。Inner Monologue 强调执行反馈对重新规划的作用[7]，Diffusion Policy 改善连续动作序列建模[8]。这些工作说明长程执行同时涉及语义理解、状态变化和低层控制，但模型能力评测仍需要把最终结果与过程错误分开记录。

相关公开资源还覆盖持续学习评测 LIBERO[6]、规模化机器人策略 RT-1[10]、Open X-Embodiment[11]、DROID[19] 和 BridgeData V2[20]。Code as Policies[12] 与 RoboDreamer[13] 分别从程序规划和世界模型角度支持决策，ALOHA[14] 与 MimicGen[15]关注低成本操作和数据生成；FurnitureBench[16]、BEHAVIOR-1K[17] 与 VLABench[18]则提供不同形式的复杂任务评测。这些工作构成研究背景，但本实验只在 CALVIN 上验证过程级失败分析。

3 方法 Methods

3.1 任务定义与符号约定 Task Definition and Notations

一条长程序列记为 G=(g1,…,g5)，其中 gi 是第 i 条语言指令。模型每一步接收当前视觉观察和 gi，输出 7 维绝对动作，包括三维位置、三维姿态和一维夹爪控制。若任务成功判定在 360 个动作步内满足，记 yi=1，否则 yi=0。标准评测在首次 yi=0 后停止。

3.2 评测总体框架 Framework

阶段	输入	输出	目的
管线验证	真实示范状态与动作	回放结果	检查环境、动作格式和成功判定
单任务测试	官方初始状态与语言指令	成功与动作步数	确认基线是否出现非零成功
标准长程评测	100 条五步序列	SR@1 至 SR@5	报告固定序列整体结果
过程诊断	失败轨迹与对照动作	偏离、动作分量、恢复	解释直接失败环节

3.3 过程级指标 Key Components

除官方序列指标外，本研究记录单任务成功率、首次失败步骤、首任务类别、重试恢复率、动作分量替换结果和位置动作距离。重试实验只在失败后重新观察并执行同一指令一次，不加入新规划器；因此它测量的是最基本的恢复能力，不属于官方成绩。

4 实验 Experiments

4.1 数据集 Datasets

实验使用 CALVIN 环境 D 的公开 debug 数据，磁盘大小约 1.3 GB，共 4468 个文件。该数据只用于管线验证和小规模实验，没有下载约 165 GB 的完整数据。三条有语言标注的验证轨迹和三个从训练数据场景状态中筛出的任务片段用于真实动作回放。

4.2 评估指标 Metrics

指标	计算方式	解释
单任务成功率	成功次数/初始状态数	基础技能在不同状态下能否完成
SR@k	连续完成不少于 k 步的序列数/总序列数	任务链随长度增加的完成情况
首次失败步骤	最早 yi=0 的位置	失败从哪里开始
恢复率	额外重试成功数/重试次数	失败后同策略能否自行恢复
位置动作距离	MCIL 与示范三维位置指令的欧氏距离均值	比较给定正确状态与自由滚动的偏离

4.3 基线方法 Baselines

实验只使用老师指定的第一个 baseline：CALVIN 官方发布的 D_D_static_rgb_baseline MCIL 检查点。没有加入第二个模型，避免把环境和模型差异同时引入。

4.4 实现细节与实验设置 Implementation Details

项目	设置
设备	RTX 5060 Laptop GPU，8 GB 显存；本实验使用 CPU 推理
原因	官方 PyTorch 1.13.1 CUDA 构建不支持当前 GPU 架构，模型权重和评测逻辑保持不变
软件	Python 3.8.20，PyTorch 1.13.1+cu117，NumPy 1.24.4，PyTorch Lightning 1.8.6，Hydra 1.1.1
随机种子	0
动作步上限	每个子任务 360 步
检查点 SHA-256	cf2bc864900ce38b85daa68300addb8fdef79cc7102bd652a99f5f1924b69346
CALVIN 代码版本	calvin_models fa03f01；calvin_env 1431a46

4.5 实验主结果 Main Results

任务	测试次数	成功次数	成功率
打开 LED	9	2	22.2%
左移滑门	9	0	0.0%
打开抽屉	9	0	0.0%

三类单任务共 27 次，整体成功 2 次。两次成功都来自打开 LED，但对应两个不同官方初始条件；其中一个条件再次独立运行仍在第 94 步成功。该结果说明管线不是完全失效，同时也显示模型对初始状态较敏感。

连续完成步数 k	成功序列数	SR@k
1	1	1.0%
2	0	0.0%
3	0	0.0%
4	0	0.0%
5	0	0.0%

100 条标准五步序列完整成功 0 条，平均连续完成 0.01 步。该结果只代表当前 debug 数据、公开检查点和 CPU 适配运行，不与官方完整数据排行榜直接比较。

第 85 条序列是唯一完成第 1 步的样本：模型先完成打开 LED，随后在第 2 步“把方块推入抽屉”失败。因此完整序列成功率仍为 0%，但 SR@1 为 1%。如果只报告完整成功率，这条部分进展会与其余 99 条第一步失败的序列一起记为 0。

固定重试实验覆盖 10 条序列，共发生 10 次重试，恢复成功 0 次，恢复率为 0.0%。

强制继续诊断覆盖 10 条序列，不在首次失败后停止，共记录 50 个步骤，其中成功 0 个。该结果只用于观察失败后的后续状态，不计入官方 SR。

4.6 **消融实验** Ablation Study

任务	真实示范	仅替换位置	仅替换姿态	仅替换夹爪
打开 LED	成功	失败	成功	失败
左移滑门	成功	失败	成功	成功
打开抽屉	成功	失败	成功	成功

三类任务只替换 MCIL 位置动作后均失败，只替换姿态仍能成功。滑门和抽屉只替换夹爪仍成功，LED 只替换夹爪则失败。LED 示范成功的关键动作步要求夹爪为负，MCIL 在该步输出为正，环境会按符号执行相反的开合状态。

任务	给定正确示范状态	模型连续执行
打开 LED	6.1 mm	133.6 mm
左移滑门	7.3 mm	72.9 mm
打开抽屉	6.9 mm	194.2 mm

给模型正确示范状态时，位置动作与示范平均相差约 6—7 毫米；模型自由滚动后扩大到 72.9—194.2 毫米。不同策略可以采用不同有效路径，所以该距离不能单独判错；结合任务失败和动作替换结果，当前证据支持“闭环位置偏离是主要直接失败环节”。

4.7 **案例分析与错误分析** Case Study and Error Study



开始状态：LED 未点亮



结束状态：LED 已点亮

图 1　MCIL 单任务成功案例，在第 94 个动作步达到成功条件



开始状态



执行 360 步后的状态

图 2　MCIL 单任务失败案例，最终未满足 LED 成功条件

成功和失败案例使用相同语言指令，但初始场景中滑门、抽屉和方块位置不同。只报告最终成功率会保留 1 或 0，却不会告诉读者机器人是否接近按钮、是否在接触时使用了正确夹爪方向，也不会说明前面偏差怎样改变了后续观察。

4.8 可视化分析 Visualizations

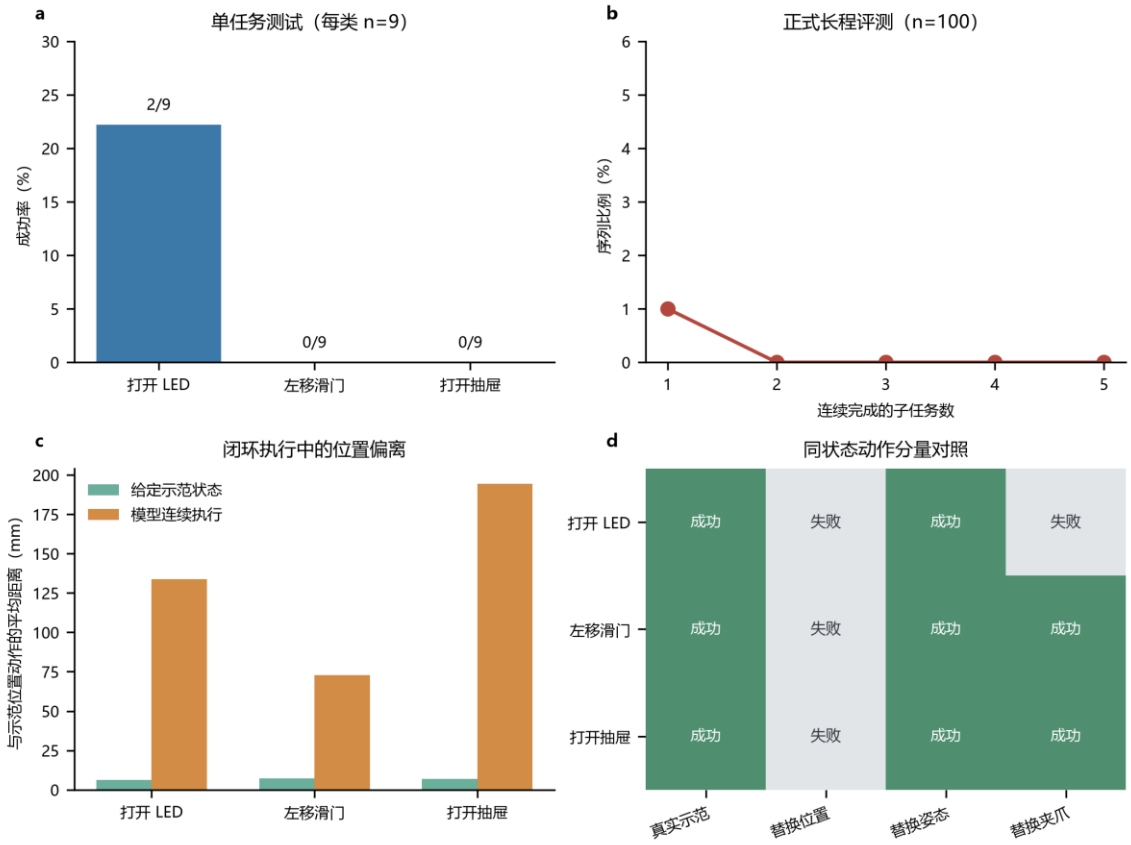


图 3　第一基线的单任务、长程序列、位置偏离和动作分量对照结果

4.9 稳健性与泛化分析 Robustness and Generalization

LED 成功条件独立复跑后得到相同的第 94 步成功，说明该结果可以重复。其余任务在多个官方初始状态上保持低成功，说明模型表现不是由单一失败截图决定。由于实验只使用 debug 数据和一个公开权重，当前结果不能外推到完整 CALVIN 数据、其他模型或真实机器人。

5 讨论 Discussion

这组实验回答了老师提出的核心问题：传统任务级 Success Rate 确实不能解释长程任务为什么失败。100 条序列的完整成功率为 0%，但其中一条已经完成 LED 后才在第二步失败；单任务结果也证明模型并非完全没有能力。动作拆分进一步把失败定位到闭环位置控制，并在 LED 案例中发现夹爪时机问题。三种证据合在一起，比单独报告 0 分更容易判断下一步应该检查模型、数据匹配还是恢复机制。

同时，过程指标也有边界。动作与示范不同不一定错误，人工失败标签只能描述可观察现象，不能直接证明网络内部原因。强制继续和额外重试改变了官方评测流程，只

能作为诊断结果。研究的价值在于建立一套较小但可复查的分析流程，而不是证明某个新模型优于现有方法。

6 研究总结 Conclusions

6.1 主要工作总结 Conclusions

本研究完成了 CALVIN 与 MCIL 的运行、真实示范回放、27 次三类单任务测试、100 条标准五步序列、动作分量替换、教师强制状态对照及重试和继续执行诊断。主要发现是：模型在少数 LED 初始条件下能够成功，但长程稳定性很弱；失败样本中闭环位置动作逐步偏离，LED 还受到关键夹爪方向影响。过程级记录能够说明失败位置和直接表现，补充终点成功率缺少的信息。

6.2 研究局限性 Limitations

实验只使用约 1.3 GB 的 debug 数据和一个 MCIL 权重，样本规模小，未使用完整训练数据，也没有加入第二个模型。GPU 架构与旧版 PyTorch 不兼容，因此采用 CPU 推理。当前标签主要来自环境状态、动作对照和人工查看，没有独立第二标注者。以上限制使结果适合作为可复现的阶段研究，不适合作为通用性能结论。

6.3 未来改进方向 Future Works

下一步可在资源允许时用完整环境 D 数据复核同一权重，并增加一个开源模型做同协议比较。评测方面可保存每一步的目标距离、接触状态和子任务前置条件，减少人工判断。若后续研究算法，可先加入轻量的执行检查与重试机制，再比较它是否降低位置偏离和错误传播。

7 参考文献 References

[1] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard, ‘CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks,’ IEEE Robotics and Automation Letters, vol. 7, no. 3, pp. 7327–7334, 2022.

[2] O. Mees, L. Hermann, and W. Burgard, ‘What Matters in Language Conditioned Robotic Imitation Learning over Unstructured Data,’ IEEE Robotics and Automation Letters, 2022.

[3] C. Lynch and P. Sermanet, ‘Language Conditioned Imitation Learning over Unstructured Data,’ Robotics: Science and Systems, 2021.

[4] A. Brohan et al., ‘RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control,’ arXiv:2307.15818, 2023.

[5] M. J. Kim et al., ‘OpenVLA: An Open-Source Vision-Language-Action Model,’ arXiv:2406.09246, 2024.

[6] B. Liu et al., ‘LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning,’ arXiv:2306.03310, 2023.

[7] W. Huang et al., ‘Inner Monologue: Embodied Reasoning through Planning with Language Models,’ arXiv:2207.05608, 2022.
[8] C. Chi et al., ‘Diffusion Policy: Visuomotor Policy Learning via Action Diffusion,’ arXiv:2303.04137, 2023.
[9] Octo Model Team et al., ‘Octo: An Open-Source Generalist Robot Policy,’ arXiv:2405.12213, 2024.
[10] A. Brohan et al., ‘RT-1: Robotics Transformer for Real-World Control at Scale,’ arXiv:2212.06817, 2022.
[11] Open X-Embodiment Collaboration et al., ‘Open X-Embodiment: Robotic Learning Datasets and RT-X Models,’ arXiv:2310.08864, 2023.
[12] J. Liang et al., ‘Code as Policies: Language Model Programs for Embodied Control,’ arXiv:2209.07753, 2022.
[13] S. Zhou et al., ‘RoboDreamer: Learning Compositional World Models for Robot Imagination,’ arXiv:2404.12377, 2024.
[14] T. Z. Zhao et al., ‘Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware,’ arXiv:2304.13705, 2023.
[15] A. Mandlekar et al., ‘MimicGen: A Data Generation System for Scalable Robot Learning using Human Demonstrations,’ arXiv:2310.17596, 2023.
[16] M. Heo et al., ‘FurnitureBench: Reproducible Real-World Benchmark for Long-Horizon Complex Manipulation,’ arXiv:2305.12821, 2023.
[17] C. Li et al., ‘BEHAVIOR-1K: A Human-Centered, Embodied AI Benchmark with 1,000 Everyday Activities and Realistic Simulation,’ arXiv:2403.09227, 2024.
[18] S. Zhang et al., ‘VLABench: A Large-Scale Benchmark for Language-Conditioned Robotics Manipulation with Long-Horizon Reasoning Tasks,’ arXiv:2412.18194, 2024.
[19] A. Khazatsky et al., ‘DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset,’ arXiv:2403.12945, 2024.
[20] H. Walke et al., ‘BridgeData V2: A Dataset for Robot Learning at Scale,’ arXiv:2308.12952, 2023.

8 **附录** Appendix

材料	**位置或说明**
核心运行代码	研究工作台/实验代码
原始 JSON 结果	研究工作台/实验结果/第一基线
汇总 CSV 和图	最终提交/实验数据汇总
复现条件	随机种子 0；每个子任务 360 步；官方任务成功判定

所有成功次数、动作步数和距离值均来自保存的 JSON 或 CSV。最终提交包不包含 CALVIN 原始数据和模型权重，以避免体积过大；代码中的路径需要按本机环境修改。